# データに基づくS社への改善策提案

提案者：谷俊磨

# 1. データの再確認

本データは1440人分の、44項目にわたる詳細な人材データでした。
また7つに分類し、いくつか例を記しました。

1. 基本的な個人属性　例: (Age, Gender)
2. 社内での位置づけ　例: (EmployeeNumber, JobRole)
3. 勤務状態　例: (DistanceFromHours, RemoteWork)
4. 給与・待遇　例: (MonthlyIncome, Incentive)
5. 職歴・勤続年数　例: (YearsAtCompany, NumCompaniesWorked)
6. 満足度　例: (EnvironmentSatisfaction, JobSatisfaction)
7. 評価　例: (PerformanceRating, PerformanceIndex)

# 1. データの再確認

本データにはAttritionとして離職の有無の行が存在しました。
ここから得られた離職率の値は16.2%でした。

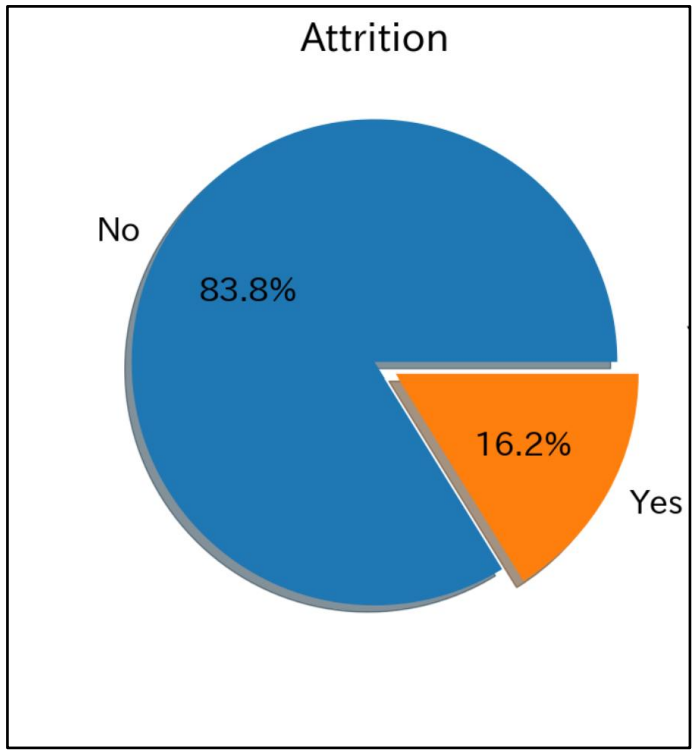



**図1　離職の有無の割合**

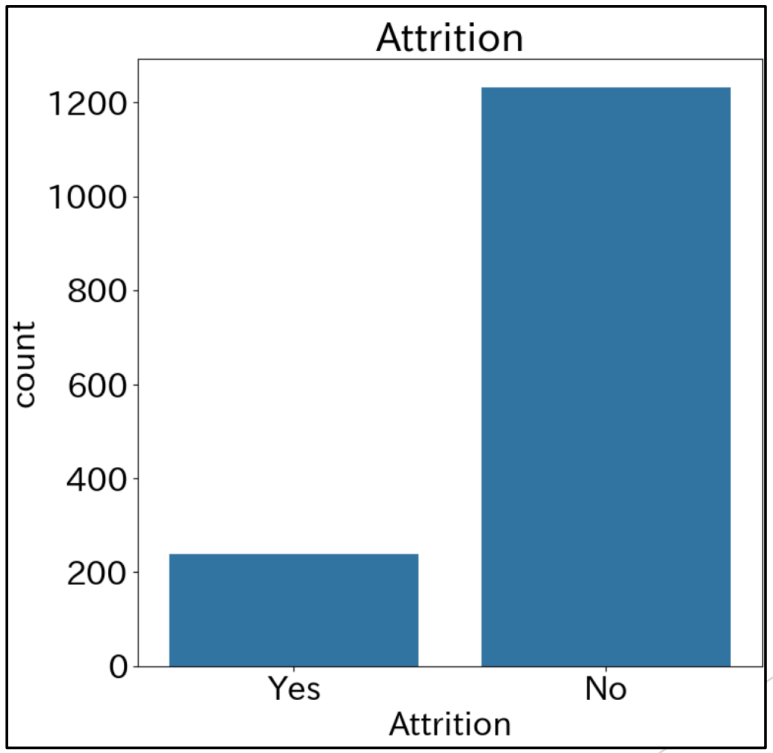



**図2　離職の有無ごとの総数**

# 2. 近年の市場動向と比較

厚生労働省が行った雇用動向調査（令和6年）のデータと比較しました。

また本データに記載されている従業員はStandardHoursやMonthlyIncomeの行より得られた値から、パートタイムではない一般労働者だと推測し、その仮定のもと進めていきます。

# 2. 近年の市場動向と比較

下のグラフは採用形態別の入職率、退職率です。
本件で注目していただきたいのは一般の離職率であり、下の点線グラフで表されているものです。
おおよそ11%前後を推移しており、S社の離職率が高いことが分かります。

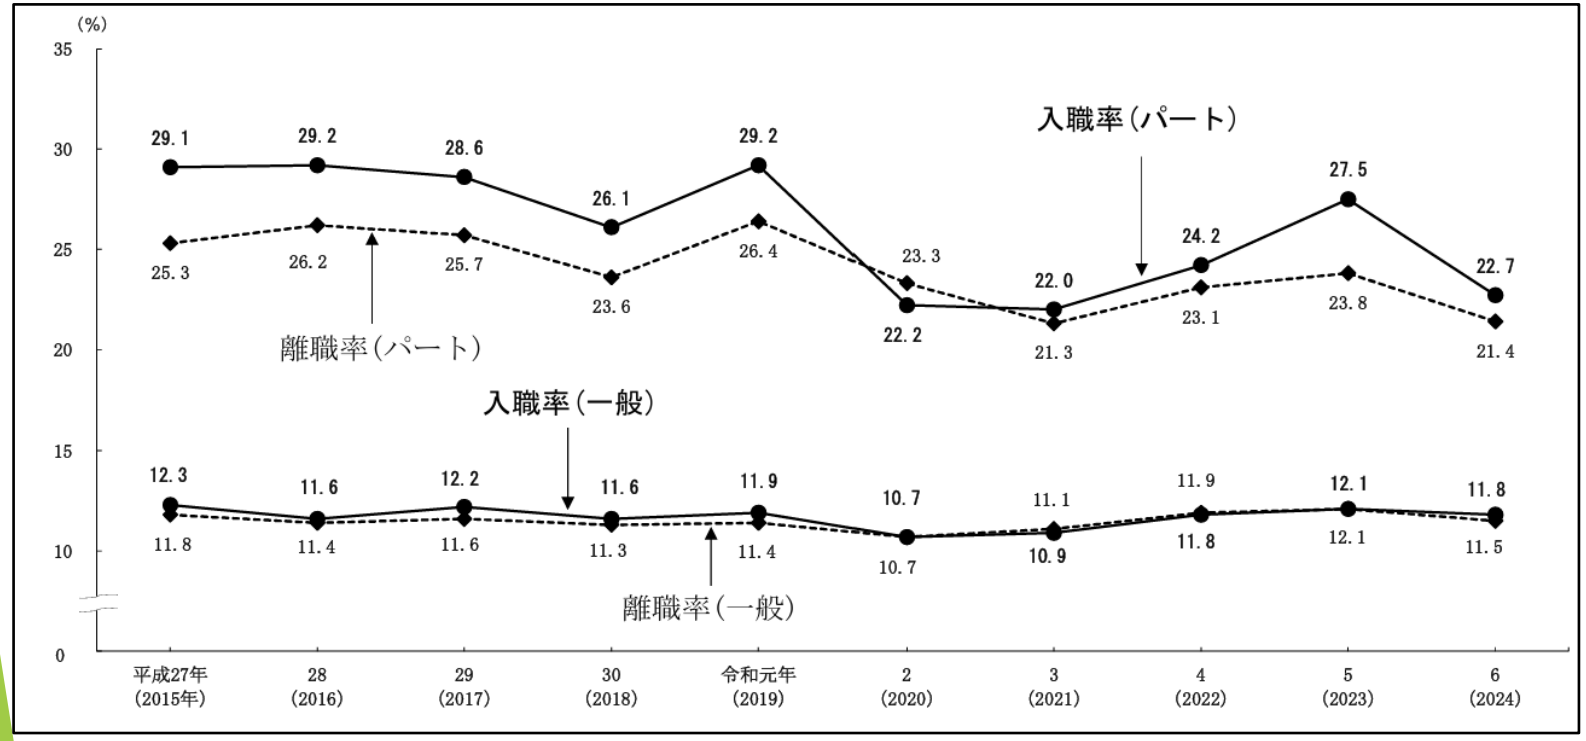



**図3　市場全体の入職率、退職率**
**[引用]※1　令和6年　雇用動向調査結果の概要　入植と離職の推移, 厚生労働省,p.3（参照 2026/07/21）**

https://www.mhlw.go.jp/toukei/itiran/roudou/koyou/doukou/25-2/dl/kekka_gaiyo-01.pdf

# 2. 近年の市場動向と比較

右の表は厚生労働省の公開した雇用動向調査で公開された離職理由の割合です。
注目すべきは個人的理由の内容です。
割合の大きいものは、被験者が感じたマイナス的な内容であり、ストレスが影響していることがデータからもわかります。

| 区分 | 計[2] | 個人的理由 | | | | | | | | | | その他の理由 | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | | 仕事の内容に興味を持てなかった | 能力・個性・資格を生かせなかった | 職場の人間関係が好ましくなかった | 会社の将来が不安だった | 給料等収入が少なかった | 労働時間、休日等の労働条件が悪かった | 結婚 | 出産・育児 | 介護・看護 | その他の個人的理由 | 定年・契約期間の満了 | 会社都合 | その他の理由（出向等を含む） |
| 令和６年（2024）（%） | | | | | | | | | | | | | | |
| 男 | 100.0 | 4.4 | 3.8 | 9.0 | 7.4 | 10.1 | 8.6 | 0.6 | 0.5 | 1.2 | 20.2 | 14.1 | 5.2 | 13.5 |
| 19歳以下 | 100.0 | 1.2 | 1.0 | 9.1 | 0.1 | 7.9 | 12.5 | － | － | 8.2 | 39.3 | 1.8 | 3.4 | 14.2 |
| 20～24歳 | 100.0 | 6.3 | 1.6 | 7.6 | 5.0 | 12.5 | 11.3 | 0.4 | 0.0 | 0.8 | 28.0 | 8.2 | 2.5 | 14.9 |
| ⋮ | | | | | | | | | | | | | | |
| 60～64歳 | 100.0 | 1.0 | 1.5 | 5.9 | 2.5 | 1.8 | 4.1 | － | － | 0.4 | 13.8 | 54.6 | 4.4 | 9.1 |
| 65歳以上 | 100.0 | 3.3 | 3.1 | 5.8 | 3.0 | 1.3 | 3.2 | － | － | 1.2 | 13.2 | 50.1 | 8.3 | 6.5 |
| 女 | 100.0 | 3.6 | 3.7 | 11.7 | 5.1 | 8.3 | 12.8 | 1.9 | 1.8 | 1.0 | 24.3 | 10.7 | 5.3 | 7.8 |
| 19歳以下 | 100.0 | 4.0 | 0.1 | 34.0 | 0.0 | 10.3 | 3.9 | － | 0.0 | 0.4 | 32.4 | 0.4 | 0.7 | 4.3 |
| 20～24歳 | 100.0 | 3.2 | 3.1 | 9.8 | 4.1 | 7.6 | 13.6 | 0.7 | 0.5 | 0.0 | 35.3 | 8.7 | 5.4 | 5.7 |
| ⋮ | | | | | | | | | | | | | | |
| 55～59歳 | 100.0 | 2.7 | 2.3 | 13.0 | 6.3 | 6.7 | 9.2 | － | － | 1.2 | 27.3 | 10.2 | 7.6 | 12.4 |
| 60～64歳 | 100.0 | 2.7 | 0.6 | 9.5 | 1.4 | 3.6 | 9.2 | － | － | 0.6 | 25.7 | 33.5 | 3.4 | 7.2 |
| 65歳以上 | 100.0 | 2.6 | 0.6 | 5.5 | 1.9 | 2.8 | 13.2 | － | － | 3.8 | 26.8 | 20.5 | 8.7 | 9.6 |
| 令和５年（2023）（%） | | | | | | | | | | | | | | |
| 男 | 100.0 | 7.4 | 5.1 | 9.1 | 5.2 | 8.2 | 8.1 | 0.3 | 0.3 | 0.5 | 17.3 | 16.9 | 5.8 | 14.0 |
| 女 | 100.0 | 5.0 | 5.4 | 13.0 | 4.6 | 7.1 | 11.1 | 1.6 | 1.6 | 1.2 | 25.1 | 9.8 | 5.3 | 6.9 |
| 前年差（ポイント） | | | | | | | | | | | | | | |
| 男 | … | −3.0 | −1.3 | −0.1 | 2.2 | 1.9 | 0.5 | 0.3 | 0.2 | 0.7 | 2.9 | −2.8 | −0.6 | −0.5 |
| 女 | … | −1.4 | −1.7 | −1.3 | 0.5 | 1.2 | 1.7 | 0.3 | 0.2 | −0.2 | −0.8 | 0.9 | 0.0 | 0.9 |

**図4　市場全体の離職理由割合**
**[引用]※2　令和6年　雇用動向調査結果の概要**
**概況全体版, 厚生労働省, p.16　（参照 2026/07/21）**
**https://www.mhlw.go.jp/toukei/itiran/roudou/koyou/doukou/25-2/dl/gaikyou.pdf**

# 3. 2章から考えられる仮説

近年の市場動向を調査した結果、S社の離職率は他と比べて
大きいことが分かりました。
また市場全体で調査された、個人的な離職理由では
何かしらの影響でストレスを感じていることが多く、
**同様の理由がS社でも発生している**という仮説のもと
調査を行いました。

# 4. データからわかる離職率との関係

まず全ての要素と離職の有無の関係を調べ
離職率が大きい要素についてまとめました。
その結果、StressRatingの大きい値が1位と3位に表示され
3章で考えた仮説に信頼性を加えることができました。

| 離職率が大きい上位１０要素 | | | |
|---|---|---|---|
| 要素名 | 具体的な値や名称 | 離職率(%) | 値や名称に該当する人数 |
| StressRating | 5 | 67.9 | 28 |
| RemoteWork | 0 | 43.2 | 44 |
| StressRating | 4 | 39.2 | 143 |
| JobRole | Sales Representative | 37.8 | 82 |
| JobInvolvement | 1 | 30.1 | 83 |
| WorkLifeBalance | 1 | 28.7 | 80 |
| EducationField | Technical Degree | 27.9 | 129 |
| JobLevel | 1 | 27.2 | 536 |
| NumCompaniesWorked | 5 | 27.0 | 63 |
| JobRole | Laboratory Technician | 26.6 | 259 |

**表1　離職率が大きい上位10要素**

# 4. データからわかる離職率との関係

StressRatingの重要性が高そうだと推測できたため、
StressRatingの分布を以下に示しました。




**図5　StressRatingとAttritionの関係**

# 5. モデル構築

離職しそうな人を先に検出できるモデルがあれば
離職率を抑えることができるため、それを目標とするモデルを
構築していきます。
要素数が多いと過学習やノイズを生むため、要素数を絞ったり、
必要そうな要素を付け加えます。
StressRatingが重要な要素だということはわかりましたが、
より細かな要素を使用しモデル構築することで
**S社専用の離職者予測モデル**を構築しようと思います。

# 5. モデル構築

以下は使用する要素です。
まだ多いですが、最初にこれを基にモデルを作成し
予測に不必要と判断された要素を削除したり、いくつかの要素
を組み合わせ、最適なモデルを見つける方針で進めていきます。

```
BusinessTravel
DistanceFromHome
EnvironmentSatisfaction
PerformanceIndex
JobInvolvement
JobSatisfaction
MonthlyAchievement
OverTime
RelationshipSatisfaction
WorkLifeBalance
RemoteWork
MonthlyIncome
StressRating
WelfareBenefits
InHouseFacility
ExternalFacility
ExtendedLeave
FlexibleWork
StressSelfResported
```

# 5. モデル構築

## モデルの評価方法

本モデルの評価方法として、AccuracyとAUCの値を参考に、
離職率を抑えたいという観点から、**Recall（離職者）を重要視**します。

Accuracy: 全体の予測がどれくらい当たったか
AUC: 離職者と非離職者をどれくらい区別できたか
Recall（離職者）: 本当に離職した人をどれくらい正しく予測できたか

また推測するデータによって目標とするAccuracyやAUC、Recallは変わります。
本データでは全員を非離職者と予測した場合
Accuracy=0.837, AUC=0.5, Recall（離職者）=0.0となります。
次のスライドからRecall = Recall（離職者）とします。

それぞれの最終的な目標値は大枠のデータから得られた値を基に設定しました。

# 5. モデル構築

非線形な関係を学習でき、
右のような要素別の重要度を測れることから、
モデルはRandom Forestを採用しました。

最初のモデルでは以下のような結果になりました。

Accuracy=0.813, AUC=0.762, Recall=0.52

| | 予測した非離職者 | 予測した離職者 |
|---|---|---|
| **本当の非離職者** | 214 | 32 |
| **本当の離職者** | 23 | 25 |

**表2　最初に試したモデルの混同行列**

| Feature | Importance |
|---|---|
| StressRating | 0.160431 |
| MonthlyIncome | 0.128937 |
| PerformanceIndex | 0.086898 |
| MonthlyAchievement | 0.081609 |
| OverTime | 0.079596 |
| ExtendedLeave | 0.072881 |
| RemoteWork | 0.069720 |
| DistanceFromHome | 0.059652 |
| JobSatisfaction | 0.049763 |
| JobInvolvement | 0.043082 |
| StressSelfReported | 0.030688 |
| EnvironmentSatisfaction | 0.026377 |
| WelfareBenefits | 0.020433 |
| WorkLifeBalance | 0.019239 |
| RelationshipSatisfaction | 0.018936 |
| BusinessTravel_Travel_Frequently | 0.018642 |
| FlexibleWork | 0.012914 |
| InHouseFacility | 0.008077 |
| BusinessTravel_Travel_Rarely | 0.006142 |
| ExternalFacility | 0.005982 |

上記の結果から最終的な目標を
**Accuracy=0.80以上、AUC=0.750以上**とし
その中でRecallの値を上昇させられるモデル設計に取り組みました。

# 5. モデル構築

先ほどの状態から要素を選別し、パラメータ調整を繰り返し、
最終的なモデルを構築しました。以下がそのモデルです。

```
use_cols = [
'DistanceFromHome',
'EnvironmentSatisfaction',
'PerformanceIndex',
'JobInvolvement',
'JobSatisfaction',
'MonthlyAchievement',
'OverTime',
'RelationshipSatisfaction',
'WorkLifeBalance',
'RemoteWork',
'MonthlyIncome',
'StressRating',
'WelfareBenefits',
'ExtendedLeave',
'FlexibleWork',
'StressSelfReported'
]


X = df[use_cols].copy()
y = df[target_col].map({"No": 0,"Yes": 1})
```

```
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)


model = RandomForestClassifier(
    n_estimators=300,
    max_depth=5,
    min_samples_leaf=5,
    class_weight="balanced",
    random_state=42
)


model.fit(X_train, y_train)


y_pred_proba = model.predict_proba(X_test)[:, 1]
threshold = 0.50
y_pred = (y_pred_proba >= threshold).astype(int)
```

# 5. モデル構築

最終的なモデルの結果は以下のようになりました。
このモデルはAccuracy=0.810,AUC=0.760であり目標値を満たし、
その中でRecallの値を0.52→0.65まで上昇することができました。

```
Accuracy: 0.8095238095238095
AUC: 0.7598238482384823
Classification report
              precision    recall  f1-score   support

非離職者→ 0       0.92      0.84      0.88       246
 離職者→ 1        0.44      0.65      0.53        48

    accuracy                           0.81       294
   macro avg       0.68      0.74      0.70       294
weighted avg       0.85      0.81      0.82       294
```

| | 予測した非離職者 | 予測した離職者 |
|---|---|---|
| **本当の非離職者** | 207 | 39 |
| **本当の離職者** | 17 | 31 |

**表3　最終的なモデルの混同行列**

# 6. 事業の改善案

このモデルを活用いただくことで、
離職率を市場水準程度に抑えられる予測が立てられます。

テストデータを使用した具体的な根拠

48÷294=16.3%が離職していた。
モデルにより31人を見抜くことができた。

詳細なカウンセリングにより15人が離職の意思を変更できた場合
→ 33÷294=11.2%が離職する　（11.2% ≒ 市場水準）

また社員全員に詳細なカウンセリングをするのではなく、
(39+31)÷294=**23.8%** のみで大丈夫です（テストデータの場合）。

したがって、本モデルで離職すると予測された方向けに
**詳細なカウンセリング**を行い、それを基に企業の改善をすることで
離職率も改善されることが予想されるため、これを改善策提案とさせていただきます。